

Systèmes bouclés échantillonnés

CM9 — Applications & Révisions

Data-based approaches · Étude de cas : pendule inversé

ECE Paris, Etienne Chassaing

1. Apprentissage de modèle
2. Model-Based Control et Reinforcement Learning
3. Conclusion — place des outils IA
4. Étude de cas : pendule inversé


Partie I

Data-based Approaches

et Application Industrielle

1. Apprentissage de modèle
2. Model-Based Control et Reinforcement Learning
3. Conclusion — place des outils IA
4. Étude de cas : pendule inversé

La boucle de commande standard



Approche classique

On connaît $G(s)$, on synthétise $C(s)$ (PID, RST...)

Questions centrales

- Peut-on identifier G directement depuis les données $\{u_k, y_k\}$ du système ?
- Peut on apprendre C directement depuis le modèle ?

Quand on ne peut pas modéliser $G(s)$

Ce dont on dispose

- Des **mesures** : ensembles de couples entrée-sortie $\{u_k, y_k\}$
- L'accès au système pour des tests en boucle ouverte **et fermée**

Reformulation : régression

Trouver $\hat{G}$ tel que :

$$\hat{y}(k) = f(u(k-1), \dots, y(k-1), \dots)$$

Attention : le temps est **implicite**, les données sont des séries temporelles ordonnées. Ce n'est pas une régression classique.

System Identification

C'est le domaine de la **System Identification** : construire un modèle dynamique $\hat{G}$ à partir de données entrée-sortie, sans équations de la physique.

Paramétrique (white / grey box)

- Équations issues de la **physique** (Newton, thermodynamique...)
- Structure connue, **paramètres à identifier** : $m, b, k \dots$
- Méthode : moindres carrés, optimisation

Exemple : moindres carrés

Mesures $\{u_k, y_k\}$, modèle $y = \theta^\top \varphi$:

$$\hat{\theta} = (\Phi^\top \Phi)^{-1} \Phi^\top Y$$

Φ : matrice de régression, Y : vecteur des sorties.

Black box (data-driven)

- Aucune hypothèse sur la **structure interne**
- Exemples : **ARX**, réseaux de neurones (NARX), GP
- Entraîné sur des mesures $\{u_k, y_k\}$

Modèle ARX (black box)

Exemple de modèle linéaire autorégressif :

$$\hat{y}(k) = \sum_{i=1}^n a_i y(k-i) + \sum_{j=1}^m b_j u(k-j)$$

Identification par moindres carrés ordinaires.


1. Apprentissage de modèle
2. Model-Based Control et Reinforcement Learning
3. Conclusion — place des outils IA
4. Étude de cas : pendule inversé

Principe

1. À chaque pas k , **prédire** la sortie sur un horizon N grâce au modèle $\hat{G}$
2. **Optimiser** la séquence $\{u_k, \dots, u_{k+N-1}\}$ minimisant :

$$J = \sum_{i=0}^{N-1} \left[(y_{k+i} - r)^{\top} Q (y_{k+i} - r) + u_{k+i}^{\top} R u_{k+i} \right]$$

3. Appliquer **seulement** u_k , puis **glisser** d'un pas



Atouts



- Contraintes sur u et y intégrées **naturellement**
- Anticipation de la consigne future (horizon glissant)
- Applicable aux systèmes **MIMO**
- Gère les **retards purs** explicitement dans le modèle

Coût

- Résolution d'un problème d'optimisation à **chaque pas** de calcul
- Exigeant en temps processeur (temps réel difficile)
- Sensible à la **qualité du modèle** $\hat{G}$

Usages : raffineries, procédés chimiques, véhicules autonomes.

RL — Reinforcement Learning



Principe

L'agent apprend par **essais/erreurs** sur un modèle simulé $\hat{G}$ — sans toucher au vrai système pendant l'entraînement.

Récompense typique

$$r_k = -\|y_k - r\|^2 - \alpha \|\Delta u_k\|^2$$

Maximiser la récompense cumulée $\sum_k \gamma^k r_k$.

Atouts

- Gère les **non-linéarités** fortes
- Pas d'équations de modèle nécessaires à la commande
- Peut découvrir des stratégies **non intuitives**

Limites

- Fragile **hors de la distribution** d'entraînement
- Conception de la **récompense** délicate
- Temps d'entraînement élevé
- Peu de **garanties de stabilité** formelles

1. Apprentissage de modèle
2. Model-Based Control et Reinforcement Learning
3. Conclusion — place des outils IA
4. Étude de cas : pendule inversé

Étude de cas — tuyau chauffé de 400 m


Contexte industriel

- Tuyau de **400 m** de long parcouru par un fluide
- Résistance chauffante en **entrée**, capteur de température en **sortie**
- Le tuyau **boucle sur lui-même** : la sortie réinjecte dans l'entrée

Retard pur de transport

Si $v = 1 \text{ m/s}$:

$$T_d = \frac{L}{v} = 400 \text{ s}$$



Tutoriel complet : etiennechassaing.com

La limite fondamentale

Aujourd'hui, on ne sait **pas apprendre le modèle ET le contrôleur simultanément** de façon robuste et garantie.

Apprendre $\hat{G}$ puis synthétiser C reste la démarche la plus sûre, mais les erreurs de modèle se propagent au contrôleur.

Le PID reste incontournable

- **Le plus versatile** : fonctionne sur des millions de systèmes industriels
- Robuste aux incertitudes de modèle
- Réglage simple, implantation triviale

Convergence des approches optimales

MPC et RL, appliqués à des systèmes linéaires avec critère quadratique, **convergent vers un PID bien réglé**.

Modélisation → Stabilité → PID → Discrétisation

Ce pipeline reste la base de l'automatique.

Partie II

Révisions — Étude de cas


Pendule inversé à propulsion brushless

1. Apprentissage de modèle
2. Model-Based Control et Reinforcement Learning
3. Conclusion — place des outils IA
4. Étude de cas : pendule inversé

Présentation du système

à compléter

à compléter



Voir la démo vidéo (Instagram)

Bon courage pour les révisions !

Questions ?

ECE Paris — Systèmes Bouclés Échantillonnés